

MINI-PROJET

Traitement de données avec Apache Spark et une base NoSQL

1. Présentation

Ce mini-projet conclut la partie "traitement et stockage de données massives" du cours (chapitres 3 – Apache Spark, et 4 – Bases NoSQL). Il s'agit de construire une petite chaîne de traitement de bout en bout : lecture d'un jeu de données volumineux, transformation/analyse avec Spark, puis persistance des résultats dans une base NoSQL (MongoDB ou Cassandra).

Objectifs pédagogiques

- Manipuler l'API DataFrame / Spark SQL pour nettoyer et agréger des données.
- Concevoir un modèle de données adapté à une base NoSQL (documents ou colonnes).
- Connecter Spark à une base NoSQL et y écrire des résultats de traitement.
- Justifier des choix techniques (partitionnement, schéma, format de stockage).

2. Modalités

Durée	3 jours à 1 semaine
Groupe	individuel
Technologies imposées	Apache Spark (PySpark ou Scala) + MongoDB ou Cassandra
Environnement	Local (Docker recommandé)

3. Sujet à choisir parmi les trois propositions

Chaque binôme choisit UN sujet. Les trois suivent la même architecture (Spark → traitement → NoSQL) mais portent sur des données différentes.

Sujet A Avis clients e-commerce

Dataset : avis produits (ex. Amazon Reviews, ou tout jeu CSV/JSON d'avis clients trouvé en ligne, min. 50 000 lignes).

- Nettoyer les avis (valeurs manquantes, doublons, notes hors échelle).
- Calculer avec Spark : note moyenne par produit/catégorie, top produits, évolution du volume d'avis dans le temps.
- Stocker dans MongoDB un document par produit avec ses statistiques agrégées.

Sujet B Retards de vols aériens

Dataset : vols et retards (ex. "Airline Delay" Kaggle, ou open data DGAC/FAA, min. 100 000 lignes).

- Calculer avec Spark : taux de retard par compagnie, par aéroport, par jour de semaine.
- Modéliser un schéma orienté colonnes dans Cassandra (ex. table partitionnée par aéroport + date).
- Écrire les agrégats calculés par Spark dans Cassandra.

4. Architecture attendue

- Ingestion : lecture du fichier source (CSV/JSON) dans un DataFrame Spark.

- Traitement : nettoyage, jointures/agrégations, au moins 3 indicateurs calculés.
- Stockage : écriture des résultats dans MongoDB (pymongo / connecteur Spark-Mongo) ou Cassandra (connecteur Spark-Cassandra).
- Bonus (facultatif) : petit script de visualisation (matplotlib/Streamlit) lisant les résultats depuis la base NoSQL.

5. Livrables

- Code source complet (scripts Spark + script de connexion NoSQL), déposé dans un dépôt Git.
- Rapport de 2 à 4 pages : contexte, choix techniques, schéma de données NoSQL, résultats obtenus, difficultés rencontrées.
- Courte soutenance orale de 5 à 10 minutes avec démonstration.

6. Barème indicatif (sur 20)

Critère	Points
Traitement Spark (correction, pertinence des indicateurs)	8
Modélisation et intégration NoSQL	6
Rapport (clarté, justification des choix)	4
Soutenance / démonstration	2

7. Ressources

- Spark : documentation officielle Apache Spark (spark.apache.org/docs).
- MongoDB : MongoDB Spark Connector (spark.mongodb.com), image Docker officielle mongo.
- Cassandra : DataStax Spark Cassandra Connector, image Docker officielle cassandra.
- Datasets ouverts : Kaggle Datasets, data.gouv.fr, AWS Open Data.

9. Consignes de rendu

Dépôt du lien Git et du rapport au format PDF sur la plateforme du cours, avant la date limite communiquée en séance. Toute soumission tardive sans justification sera pénalisée selon le barème habituel du département.